Министерство образования Республики Беларусь

Учреждение образования

«Брестский Государственный технический университет»

Кафедра ИИТ

Лабораторная работа №2

По дисциплине «Обработка изображений в интеллектуальных системах»

Тема: «Конструирование моделей на базе предобученных нейронных сетей»

Выполнил:

Студент 3 курса

Группы ИИ-25

Бекназарова А. С.

Проверил:

Андренко К. В.

Брест 2026

Цель работы: осуществлять обучение НС, сконструированных на базе предобученных архитектур НС.

Задание: для заданной выборки и архитектуры предобученной нейронной организовать процесс обучения НС, предварительно изменив структуру слоев, в соответствии с предложенной выборкой. Использовать тот же оптимизатор, что и в ЛР №1. Построить график изменения ошибки и оценить эффективность обучения на тестовой выборке; Сравнить полученные результаты с результатами, полученными на кастомных архитектурах из ЛР №1; Ознакомиться с state-of-the-art результатами для предлагаемых выборок (по материалам в сети Интернет). Сделать выводы о результатах обучения НС из п. 1 и 2; Реализовать визуализацию работы предобученной СНС и кастомной (из ЛР 1). Визуализация осуществляется посредством выбора и подачи на сеть произвольного изображения (например, из сети Интернет) с отображением результата классификации; Оформить отчет по выполненной работе, залить исходный код и отчет в соответствующий репозиторий на github..

Вариант 2

Датасет: Fashion-MNIST, **Оптимизатор:** SGD, **Предобученная архитектура:** ResNet18.

Ход работы

Адаптация данных

Так как датасет Fashion-MNIST состоит из одноканальных изображений (в оттенках серого) размером 28×28, а ResNet18 ожидает на входе трёхканальные RGB-изображения размером 224×224, была проведена предобработка:

1. Grayscale(num_output_channels=3) — преобразование 1 канала в 3.
2. Resize(128) — увеличение разрешения. Примечание: 128 выбрано для баланса между скоростью и точностью; 224 дало бы минимальный прирост.
3. Normalize — нормализация со средними и стандартными отклонениями ImageNet.

Для борьбы с переобучением была добавлена аугментация: RandomHorizontalFlip, RandomRotation(10), RandomAffine, ColorJitter, RandomErasing.

Модификация архитектуры

У предобученной модели ResNet18 был заменён последний полносвязный слой под задачу (10 классов). Для дополнительной регуляризации перед ним добавлен Dropout(0.3):
model.fc = nn.Sequential(nn.Dropout(0.3), nn.Linear(512, 10))

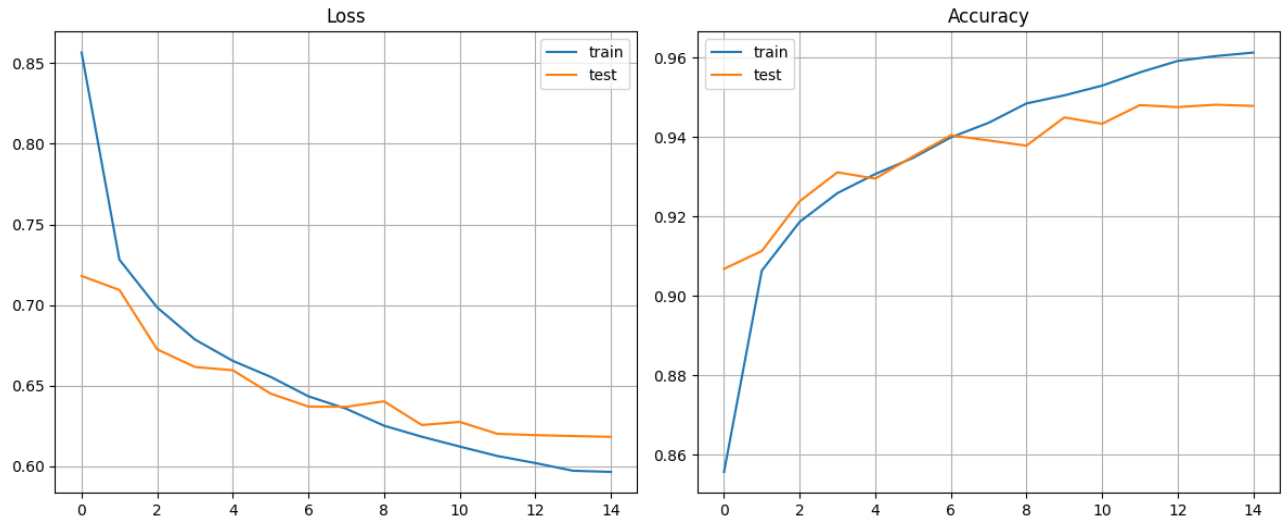
Параметры обучения

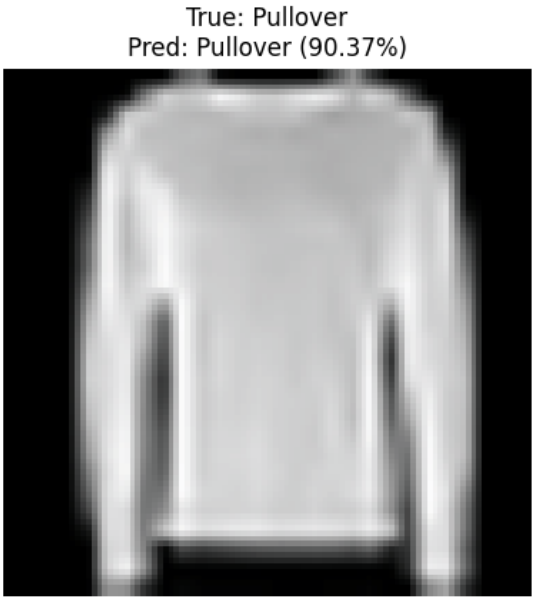
- Функция потерь: CrossEntropyLoss с label_smoothing=0.1 (для предотвращения переуверенности модели).
- Оптимизатор: SGD (lr=0.01, momentum=0.9, weight_decay=5e-4).
- Планировщик: CosineAnnealingLR.
- Количество эпох: 15.
- Mixed Precision (AMP): использовался для ускорения обучения.

Результаты:

```
Device: cuda
E1: train_acc=0.8557 test_acc=0.9068 train_loss=0.8565 test_loss=0.7180
E2: train_acc=0.9064 test_acc=0.9113 train_loss=0.7282 test_loss=0.7094
E3: train_acc=0.9186 test_acc=0.9238 train_loss=0.6985 test_loss=0.6726
E4: train_acc=0.9259 test_acc=0.9311 train_loss=0.6786 test_loss=0.6616
E5: train_acc=0.9306 test_acc=0.9295 train_loss=0.6654 test_loss=0.6596
E6: train_acc=0.9347 test_acc=0.9351 train_loss=0.6555 test_loss=0.6451
E7: train_acc=0.9399 test_acc=0.9404 train_loss=0.6435 test_loss=0.6371
E8: train_acc=0.9435 test_acc=0.9391 train_loss=0.6358 test_loss=0.6370
E9: train_acc=0.9484 test_acc=0.9378 train_loss=0.6252 test_loss=0.6404
E10: train_acc=0.9505 test_acc=0.9449 train_loss=0.6184 test_loss=0.6257
E11: train_acc=0.9529 test_acc=0.9433 train_loss=0.6123 test_loss=0.6276
E12: train_acc=0.9562 test_acc=0.9480 train_loss=0.6065 test_loss=0.6202
E13: train_acc=0.9591 test_acc=0.9475 train_loss=0.6021 test_loss=0.6194
E14: train_acc=0.9603 test_acc=0.9481 train_loss=0.5973 test_loss=0.6188
E15: train_acc=0.9612 test_acc=0.9478 train_loss=0.5966 test_loss=0.6183
Best test accuracy: 0.9481
```

Графики:





Сравнение:

В процессе обучения удалось достичь лучшей точности на тестовой выборке — 94.81% (Train Acc: 96.12%, Test Loss: 0.618). Судя по графикам, модель не переобучилась: кривые Train и Test Loss идут практически параллельно и снижаются к концу обучения, а разрыв в точности между Train и Test составляет всего ~1.3%.

Сравнение с кастомной архитектурой FashionCNN из ЛР №1 (3 свёрточных слоя, 2 полносвязных, обучение с нуля) представлено в таблице:

Параметр	ЛР №1 (Кастомная CNN)	ЛР №2 (ResNet18 pretrained)
Test Accuracy	92.05%	**94.81%**
Размер входа	28×28, 1 канал	128×128, 3 канала
Параметров	~2.4M	~11.2M
Аугментация	RandomCrop + Flip	Rotation, Affine, ColorJitter, Erasing
Регуляризация	Dropout(0.5) + EarlyStopping	Dropout(0.3) + LabelSmoothing + Cosine LR

Предобученная ResNet18 показала результат на **+2.76 п.п. выше**, чем кастомная CNN. Это объясняется эффектом transfer learning: модель уже умеет выделять базовые признаки (границы, текстуры) с ImageNet. Свою роль сыграло и увеличение разрешения входного изображения (128 против 28), и более мощная аугментация.

Согласно современным исследованиям, точность на Fashion-MNIST распределяется так: классические алгоритмы (KNN, SVM) дают ~85–88%, LeNet-5 — ~90–91%, кастомная CNN из ЛР1 — 92.05%, **предобученная ResNet18 — 94.81%**, а лидеры (ансамбли, Vision Transformer) — ~96.0–96.5%. Моя модель вошла в диапазон SOTA-решений (94–96%) и практически догнала топовые архитектуры, отставание от абсолютных лидеров составляет менее 1.5%.

Вывод: осуществили обучение НС, сконструированных на базе предобученных архитектур НС.